

Universidad Politécnica
de Madrid

Escuela Técnica Superior de Ingenieros Informáticos

Máster en Inteligencia Artificial



Inteligencia Artificial Explicable

Proyecto Práctico Tema 2
Fase I: Árbol de decisión

Grupo 3

Benasco Sánchez, Damián	d.benasco@alumnos.upm.es
Sánchez Carmona, Germán	german.sanchez.carmona@alumnos.upm.es
Vega Ortiz, Jorge Enrique	jorge.vega@alumnos.upm.es

Madrid, 25 de septiembre de 2026

Índice general

1. Introducción **2**
1.1. Problema y objetivo 2

2. Método **3**
2.1. Preparación de los datos 3
2.2. Algoritmo de clasificación 3
2.3. Selección de la complejidad 3
2.4. Selección de variables 4
2.5. Umbral y explicaciones locales 4

3. Resultados **5**
3.1. Resumen de la evaluación 5
3.2. Complejidad y selección de variables 5
3.3. Umbral de clasificación 8

4. Modelos **10**
4.1. Interpretación global del árbol 10
4.2. Explicaciones locales 12

5. Discusión **13**
5.1. Rendimiento frente a interpretabilidad 13
5.2. Limitaciones 13

6. Conclusión **14**

7. Uso de la Inteligencia Artificial Generativa **15**

Capítulo 1

Introducción

1.1. Problema y objetivo

El objetivo del proyecto es predecir si un cliente tendrá dificultades de pago el mes siguiente, variable `payment_difficulty_next_month`. Esta entrega corresponde a la Phase I del statement y se limita deliberadamente al modelo lógico: un árbol de decisión. Por tanto, el propósito no es únicamente obtener una predicción, sino producir reglas que permitan entender qué perfiles son asignados a cada clase y justificar el compromiso entre rendimiento y legibilidad.

El análisis se realiza sobre el conjunto de entrenamiento, que contiene 25 000 observaciones y 15 predictores. El conjunto de test se reserva para la entrega final y no interviene en el desarrollo de esta fase. Dado que la clase positiva es minoritaria, la evaluación debe considerar el comportamiento del modelo en ambas clases.

El informe describe la preparación de los datos, la selección del árbol, sus resultados y las explicaciones globales y locales. La interpretación se centra en el comportamiento aprendido por el modelo, sin atribuir efectos causales a las variables.

Capítulo 2

Método

2.1. Preparación de los datos

Se separó `row_id` de los predictores y de la variable objetivo. Las variables categóricas se transformaron con `OneHotEncoder` dentro de un flujo de modelado; las numéricas se mantuvieron sin escalado. El conjunto de test no se utilizó durante el desarrollo.

La evaluación empleó 5-fold stratified cross-validation, manteniendo aproximadamente la misma proporción de clases en cada fold. Se registraron accuracy, balanced accuracy, F1 y ROC-AUC. La ROC-AUC se utilizó para comparar configuraciones sin depender de un umbral concreto.

2.2. Algoritmo de clasificación

Se utilizó un árbol de decisión CART para clasificación, implementado mediante `DecisionTreeClassifier` de `scikit-learn`. CART construye el modelo mediante particiones binarias sucesivas, en cada nodo selecciona una variable y un umbral que separan las observaciones en dos ramas. El criterio utilizado fue Gini, que es la configuración por defecto del clasificador y mide la impureza de cada partición. Este algoritmo resulta adecuado para la Phase I porque sus decisiones pueden expresarse directamente como reglas y no requiere escalar las variables numéricas.

Se optó por CART y no por un Generalized Optimal Sparse Decision Tree (GOSDT). Aunque GOSDT busca árboles óptimos y dispersos, está pensado para variables discretas, mientras que este problema incluye predictores numéricos.

2.3. Selección de la complejidad

Como referencia se ajustó primero un árbol sin restricciones.

A continuación se exploraron distintas profundidades máximas y tamaños mínimos de hoja, con el objetivo de identificar un compromiso razonable entre rendimiento predictivo e interpretabilidad. En concreto, se recorrió un rango de profundidades y varios tamaños mínimos de hoja, comparando las métricas de validación cruzada con el tamaño resultante del árbol. La selección prioriza estructuras simples cuando su rendimiento es comparable al de alternativas más complejas.

2.4. Selección de variables

Con la complejidad fijada se realizó una selección forward de predictores, partiendo de un conjunto vacío. En cada paso se añadió la variable que más mejoraba la ROC-AUC media y se escogió el menor subconjunto cuyo resultado quedaba dentro de un error estándar del mejor. Cada candidato se evaluó con el mismo 5-fold stratified cross-validation, ajustando el preprocesado dentro de cada fold para evitar usar datos de validación. Cabe destacar que la estimación de esta selección es ligeramente optimista porque selección y evaluación comparten los folds.

2.5. Umbral y explicaciones locales

Después de fijar la configuración, el árbol se reentrenó con el conjunto de entrenamiento. El umbral se eligió a partir de predicciones out-of-fold, buscando maximizar la balanced accuracy. Para las explicaciones locales se seleccionó un caso correctamente clasificado de cada clase.

Capítulo 3

Resultados

3.1. Resumen de la evaluación

La tabla resume el modelo lógico de esta entrega y sus métricas. Las métricas OOF se obtuvieron con una predicción out-of-fold por observación; el ROC-AUC es la media de los cinco folds del ajuste final.

Clasificador	Configuración principal	Resultado de validación cruzada
DecisionTreeClassifier	`max_depth=2`, `min_samples_leaf=200`; 2 predictores por forward selection; umbral 0.09	Accuracy OOF = 0.548; balanced accuracy OOF = 0.657; F1 OOF = 0.443; ROC-AUC CV = 0.7237 (desv. 0.0069)

Cuadro 3.1: Resultado del modelo lógico de Phase I.

3.2. Complejidad y selección de variables

El árbol irrestricto alcanzó casi ajuste perfecto sobre entrenamiento (ROC-AUC aproximada de 1.000), pero generalizó mal con un ROC-AUC medio de 0.595 y una estructura de 8 911 nodos, 4 456 hojas y profundidad 40.

La figura 3.1 muestra la separación entre entrenamiento y validación según el árbol tiene cada vez más hojas.

Para fijar la complejidad se exploraron profundidades de 1 a 15 (figuras 3.2 y 3.3). El mejor ROC-AUC medio se obtuvo con `max_depth=6` (0.7532), pero la mayor balanced accuracy (0.6496) y el mayor F1 (0.4515) se obtuvieron con `max_depth=2`. Se eligió `max_depth=2` para priorizar la interpretabilidad, haciendo que el árbol resultante tenga 7 nodos y 4 hojas, con una accuracy media de 0.7986, balanced accuracy de 0.6496, F1 de 0.4515 y ROC-AUC de 0.7237.

La figura 3.3 muestra que el número de hojas crece de forma aproximadamente geométrica con la profundidad. Se pasa de 4 hojas con profundidad 2 a 63 con profundidad 6 y a más de 1 400 con profundidad 15. Como cada hoja corresponde a una regla, este crecimiento acelerado hace que las profundidades mayores sean cada vez más difíciles de inspeccionar, lo que refuerza la elección de una estructura compacta de dos niveles.

A continuación, se probaron tamaños mínimos de hoja de 1, 10, 25, 50, 100, 200

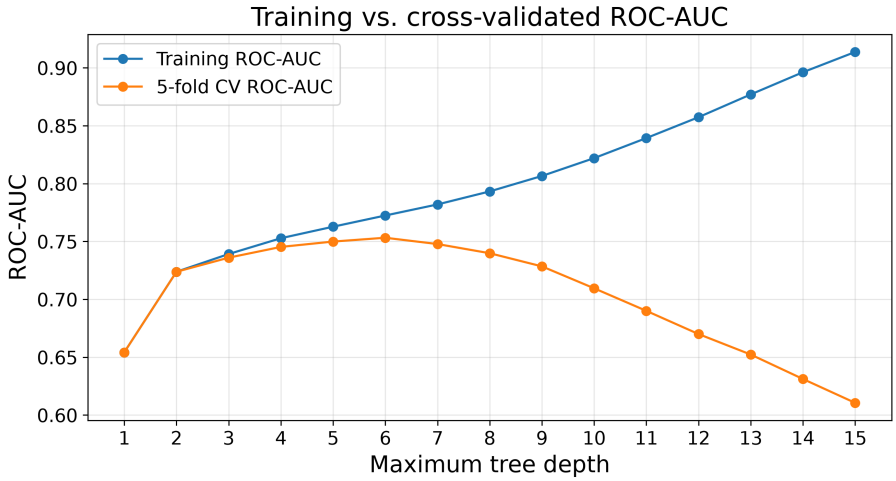


Figura 3.1: ROC-AUC de entrenamiento y de validación cruzada frente a la profundidad máxima del árbol.

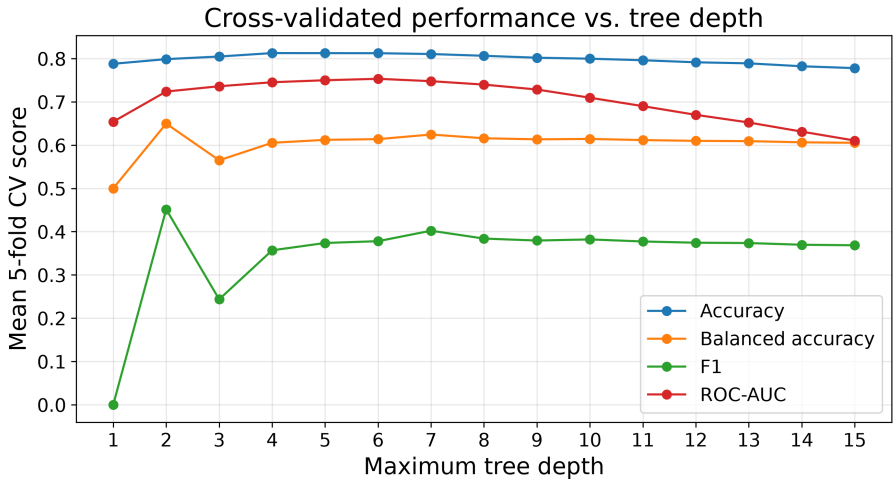


Figura 3.2: Métricas de validación cruzada frente a la profundidad máxima.

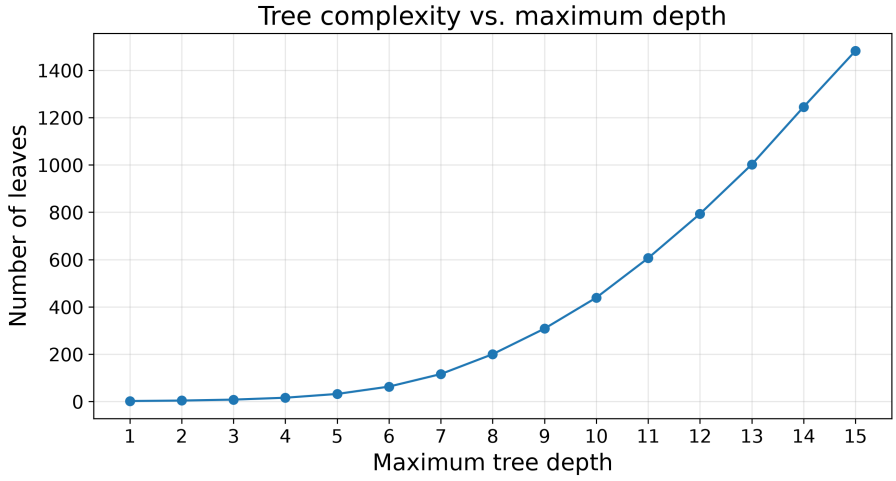


Figura 3.3: Número de hojas del árbol frente a su profundidad máxima.

y 500 con profundidades de 2 a 6 (figura 3.4). En las profundidades mayores el parámetro sí modifica ligeramente las métricas y la estructura, pero para la profundidad seleccionada todos los valores produjeron las mismas métricas y el mismo árbol de 7 nodos y 4 hojas. Con solo dos niveles, la hoja más pequeña contiene alrededor de 1 800 observaciones, de modo que la restricción nunca llega a activarse: `min_samples_leaf` no es un hiperparámetro relevante en este modelo y se fija en 200 de forma nominal, sin que ello altere el árbol final.

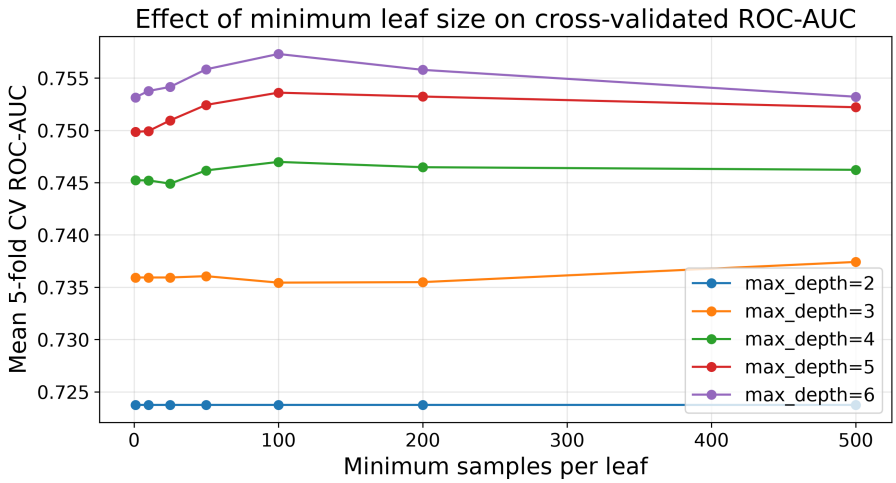


Figura 3.4: ROC-AUC de validación cruzada frente al tamaño mínimo de hoja, para distintas profundidades.

Con la complejidad fijada se procedió a la selección forward de predictores, añadiendo en cada paso la variable que más mejoraba la ROC-AUC y escogiendo el menor subconjunto dentro de un error estándar del mejor (figura 3.5). El modelo completo con los 15 predictores alcanzó un ROC-AUC medio de 0.7237 (EE 0.0028), y el subconjunto retenido fue de dos variables: `latest_repayment_status` y `payment_to_bill_ratio_6m`. El árbol final con estas dos variables mantiene 7 nodos y 4 hojas. Cabe destacar que la estimación es ligeramente optimista porque selección y evaluación comparten los folds.

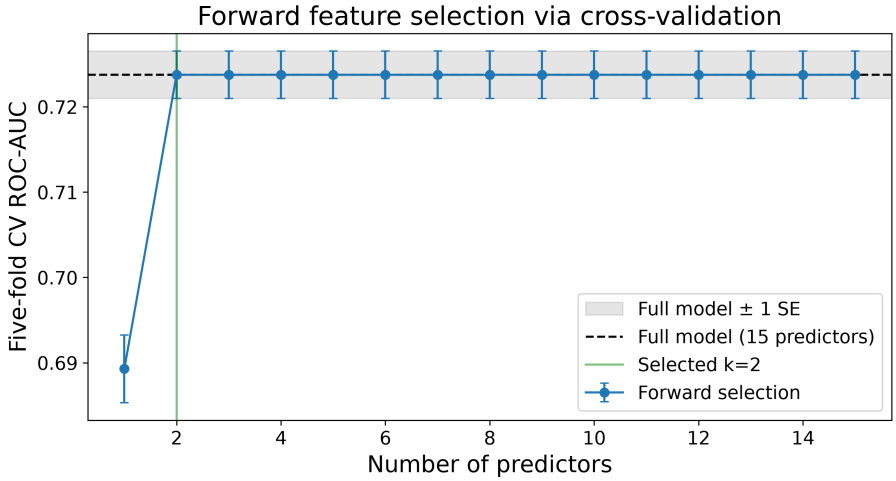


Figura 3.5: Selección forward de predictores mediante validación cruzada, con la banda de un error estándar del modelo completo y el subconjunto elegido.

3.3. Umbral de clasificación

El umbral se eligió a partir de predicciones out-of-fold, buscando maximizar la balanced accuracy (figura 3.6). El valor seleccionado fue 0.09, con balanced accuracy OOF de 0.657, accuracy de 0.548, precisión de 0.300 y recall de 0.846 para la clase 1. El umbral que maximiza F1 es 0.22 (F1 = 0.454), pero se priorizó la balanced accuracy por el desbalanceo de clases: en este problema, omitir un cliente con dificultad puede ser más costoso que revisar un caso adicional.

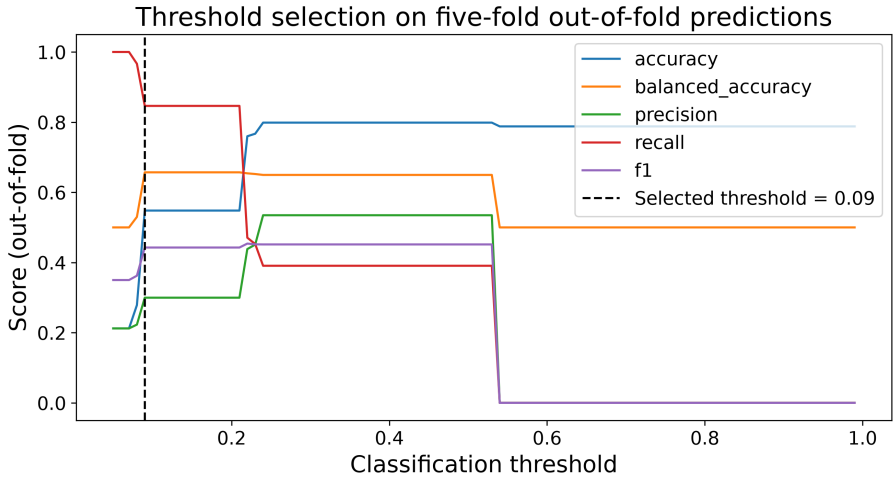


Figura 3.6: Selección del umbral de clasificación sobre predicciones out-of-fold, maximizando la balanced accuracy.

La figura 3.7 muestra la distribución de probabilidades out-of-fold por clase real, y la figura 3.8 la matriz de confusión resultante con el umbral seleccionado.

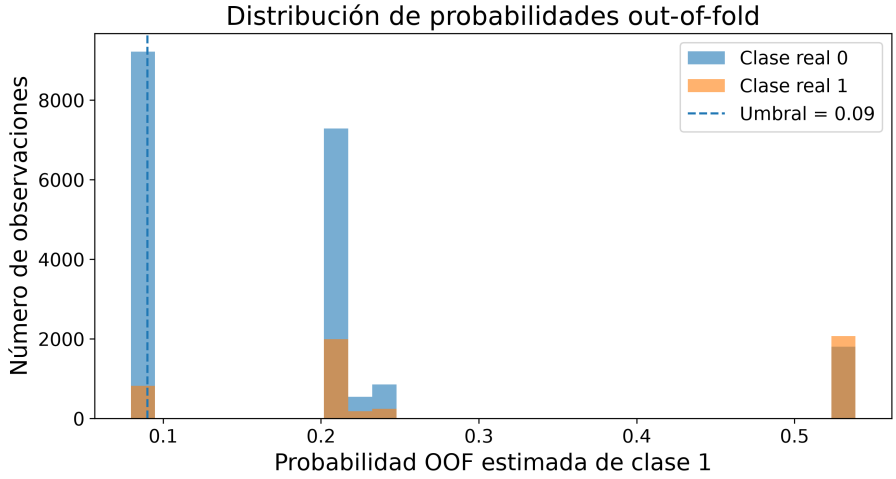


Figura 3.7: Distribución de probabilidades out-of-fold por clase real, con el umbral seleccionado.

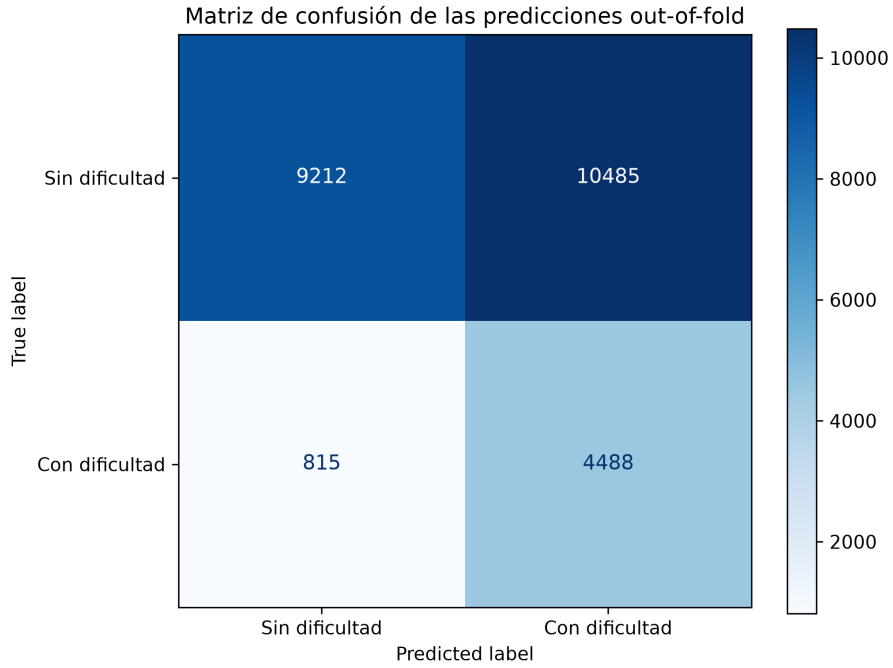


Figura 3.8: Matriz de confusión de las predicciones out-of-fold con el umbral seleccionado.

Capítulo 4

Modelos

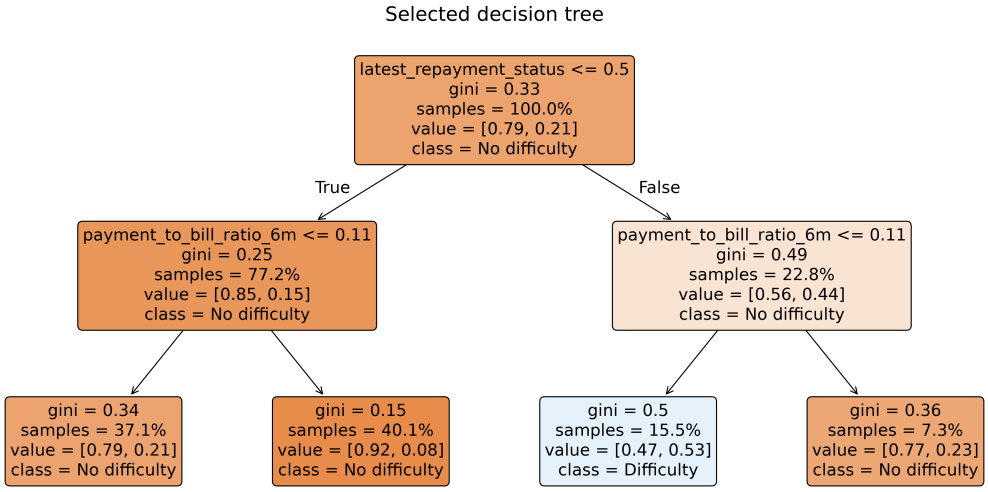


Figura 4.1: Árbol de decisión final. Cada nodo muestra la condición de división, la impureza de Gini, el porcentaje de muestras y la distribución de clases; cada hoja indica la clase predicha.

4.1. Interpretación global del árbol

La figura 4.1 muestra el árbol final, cuya estructura se interpreta a continuación.

El árbol tiene profundidad dos y exige al menos 200 observaciones por hoja. Su comportamiento se apoya únicamente en dos variables de comportamiento de pago: `latest_repayment_status`, con una importancia basada en impureza de 0.655, y `payment_to_bill_ratio_6m`, con 0.345 (figura 4.2). Esta ordenación describe el uso que el modelo hace de las variables, no una relación causal.

La raíz divide según `latest_repayment_status` en 0.5. Si el estado de devolución es bajo (0.5 o menos), ambas hojas predicen ausencia de dificultad, con probabilidades estimadas de 0.215 o 0.081 según el ratio de pago. Si el estado es alto (más de 0.5), el modelo distingue después según `payment_to_bill_ratio_6m` en 0.105: la hoja con ratio bajo concentra la mayor probabilidad de dificultad (0.535), mientras que la hoja con ratio alto baja a 0.233. Las hojas terminales asignan la clase mayoritaria de las observaciones que alcanzan cada región y usan su frecuencia de clase 1 como probabilidad estimada. Así, el modelo puede leerse como una colección de reglas, ya

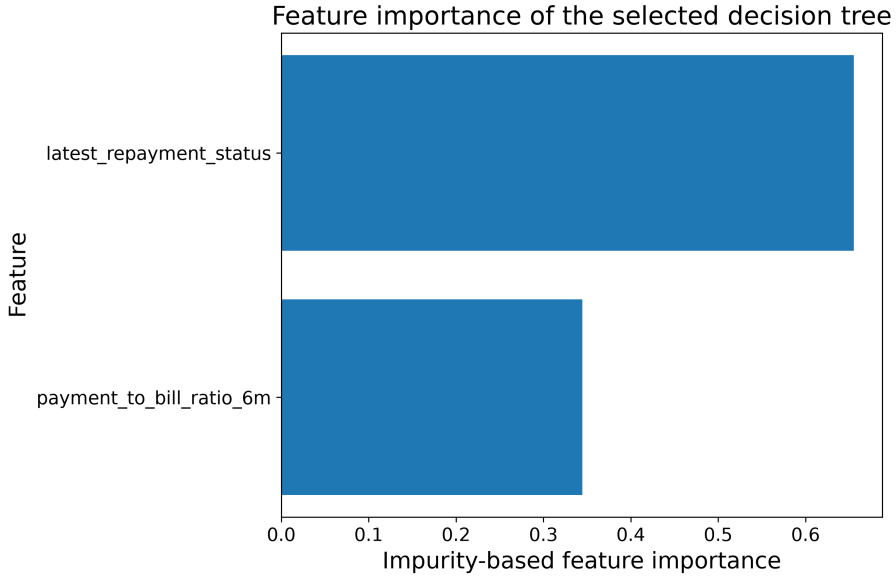


Figura 4.2: Importancia basada en impureza de las variables usadas por el árbol final.

que una observación sigue una secuencia de condiciones hasta una hoja y recibe la probabilidad de dificultad observada en esa hoja.

Las hojas extremas resumen el comportamiento del modelo. La hoja de mayor riesgo (nodo 5) corresponde a `latest_repayment_status` > 0.5 y `payment_to_bill_ratio_6m` ≤ 0.105, con una probabilidad estimada de clase 1 de 0.535 y 3 875 observaciones. La de menor riesgo (nodo 3) corresponde a `latest_repayment_status` ≤ 0.5 y `payment_to_bill_ratio_6m` > 0.105, con 0.081 y 10 027 observaciones (figura 4.3).

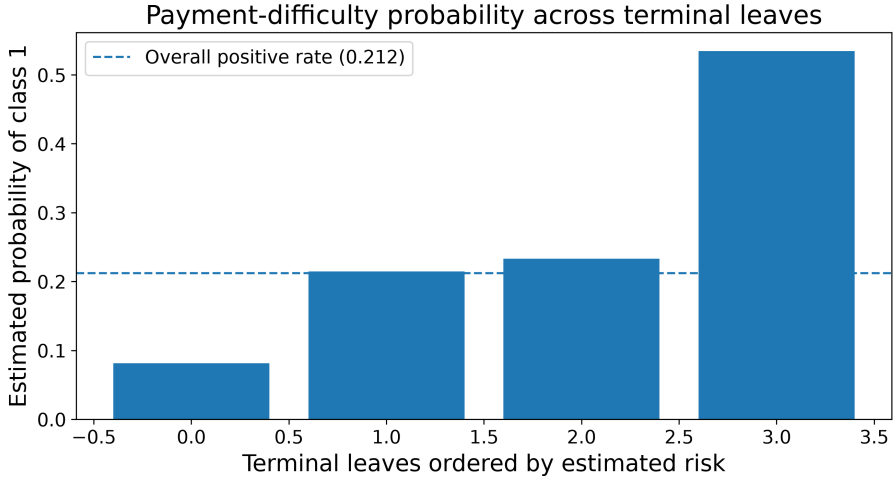


Figura 4.3: Probabilidad estimada de dificultad en cada hoja terminal, ordenadas por riesgo, junto con la tasa positiva global.

Estas reglas describen asociaciones del predictor, no causas del impago. Por ello, que el árbol asocie determinados perfiles de pago con mayor riesgo no permite concluir que las variables provoquen la dificultad posterior.

4.2. Explicaciones locales

Se conservaron dos observaciones correctamente clasificadas mediante predicciones out-of-fold, una de cada clase. Para `CR26-125466`, cuya clase real es 1, el árbol estima una probabilidad de aproximadamente 0.233 y, con el umbral seleccionado de 0.09, la clasifica como dificultad (con el umbral por defecto de 0.5 se clasificaría como ausencia). Su camino es `latest_repayment_status` > 0.5 y `payment_to_bill_ratio_6m` > 0.105. Para `CR26-103063`, cuya clase real es 0, estima una probabilidad de clase 1 de aproximadamente 0.081 y la clasifica como ausencia de dificultad tanto con 0.5 como con 0.09; su camino es `latest_repayment_status` ≤ 0.5 y `payment_to_bill_ratio_6m` > 0.105.

La explicación de cada caso es su camino desde la raíz hasta la hoja terminal: las condiciones sobre las dos variables seleccionadas se combinan, y la probabilidad de la hoja resume la proporción de casos positivos en esa región. Las figuras 4.4 y 4.5 muestran el árbol con el camino recorrido por cada observación resaltado.

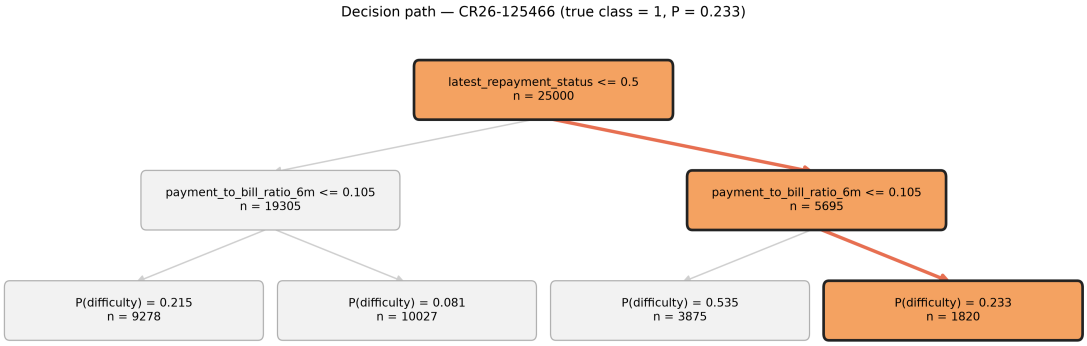


Figura 4.4: Camino de decisión de CR26-125466 (clase real 1) resaltado sobre el árbol final.

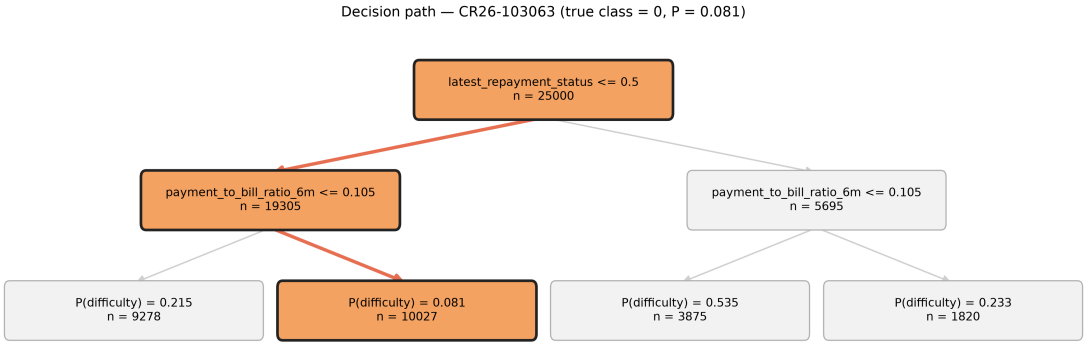


Figura 4.5: Camino de decisión de CR26-103063 (clase real 0) resaltado sobre el árbol final.

Los caminos de decisión no cambian al modificar el umbral, ya que este solo convierte la probabilidad estimada de la hoja en una clase. Esta forma de explicación es directamente verificable y adecuada para un modelo lógico, aunque no implica que cada condición aislada sea suficiente ni causal. Los mismos casos se utilizarán con logística y EBM en la entrega final para comparar explicaciones.

Capítulo 5

Discusión

5.1. Rendimiento frente a interpretabilidad

El árbol irrestricto memoriza el entrenamiento y produce miles de hojas (ROC-AUC de entrenamiento de 1.000 frente a 0.595 en validación cruzada, con 8 911 nodos y 4 456 hojas), por lo que no es adecuado para explicar decisiones.

Entre los árboles restringidos, la profundidad 6 maximizó el ROC-AUC medio (0.7532), pero la profundidad 2 maximizó la balanced accuracy (0.6496) y el F1 (0.4515). Se eligió la profundidad 2 para priorizar la interpretabilidad: el árbol final tiene 7 nodos y 4 hojas, con un ROC-AUC de 0.7237. La selección forward redujo además los predictores de 15 a dos sin pérdida de ROC-AUC (0.7237 en ambos casos), de modo que el compromiso entre rendimiento y legibilidad se resuelve con una estructura muy compacta. En esta profundidad, `min_samples_leaf` no llega a activarse, por lo que la complejidad final la determina únicamente la profundidad.

La selección de variables favorece una explicación breve, aunque variables correlacionadas podrían producir subconjuntos diferentes. Además, la selección no está anidada en una evaluación externa, por lo que el resultado debe considerarse una estimación de desarrollo.

5.2. Limitaciones

Se optó por CART en lugar de un árbol óptimo y disperso (GOSDT) porque este último está pensado para variables discretas, mientras que el problema incluye predictores numéricos.

El umbral elegido (0.09) mejora la detección de dificultades a costa de más falsas alarmas. Su conveniencia depende del coste relativo de ambos errores y debería revisarse antes de un uso operativo.

Por último, las reglas describen asociaciones del predictor, no causas del impago. Las variables retenidas resumen comportamiento de pago reciente y pueden reflejar información previa sobre la situación del cliente, por lo que no debe atribuírseles un efecto causal.

Capítulo 6

Conclusión

La Phase I construye un modelo lógico para predecir `payment_difficulty_next_month` con un árbol de decisión interpretable. La validación cruzada mostró que el árbol irrestricto sobreajusta; limitarlo a profundidad dos y 200 observaciones por hoja, y conservar dos predictores, produce un compromiso más útil entre generalización y legibilidad. La ROC-AUC media es aproximadamente 0.724 y el modelo identifica mejor la clase minoritaria cuando se usa el umbral 0.09, con una balanced accuracy out-of-fold de 0.657 y un recall de 0.846 para la clase 1.

Las reglas aprendidas se apoyan únicamente en el comportamiento reciente de pago: `latest_repayment_status` y `payment_to_bill_ratio_6m`. Las explicaciones globales y locales permiten rastrear cada predicción hasta una hoja, pero deben entenderse como asociaciones predictivas y no causales.

Para Phase II quedan pendientes la regresión logística y el Explainable Boosting Machine, la comparación de sus explicaciones sobre las mismas observaciones y la generación de predicciones para `test.csv`. También será necesario revisar la selección del umbral conforme a los costes de error que se definan para la entrega final.

Capítulo 7

Uso de la Inteligencia Artificial Generativa

Se utilizaron ChatGPT, Codex, OpenCode y GitHub Copilot como herramientas de apoyo para profundizar en el uso de las librerías y herramientas necesarias, comprender con mayor detalle la implementación y asistir en la redacción del informe.

Estas herramientas no sustituyeron el análisis ni la toma de decisiones del grupo. El código, las métricas, la configuración del árbol, la selección de variables y las explicaciones fueron revisados por los autores. La responsabilidad sobre el código, la interpretación y todo el contenido final del informe corresponde exclusivamente al grupo.